Predição do Número de Estudantes Desvinculados em Cursos de Graduação no Brasil Utilizando Técnicas de Machine Learning

README do projeto • Censo da Educação Superior • Python e Machine Learning

1. Sobre o projeto

Este projeto tem como objetivo desenvolver um modelo de Machine Learning capaz de estimar o número de estudantes desvinculados em cursos de graduação no Brasil, utilizando dados do Censo da Educação Superior.

A proposta é investigar em que medida características acadêmicas, institucionais, geográficas e administrativas estão associadas ao número de estudantes desvinculados, além de avaliar a capacidade preditiva de modelos de regressão.

O projeto utiliza Python e bibliotecas de Ciência de Dados e Machine Learning, com desenvolvimento realizado em notebooks Jupyter.

2. Objetivo

Desenvolver e avaliar modelos de regressão capazes de estimar a variável-alvo `QT_SIT_DESVINCULADO`, que representa o número de estudantes com situação de vínculo classificada como desvinculada.

O problema é tratado como uma tarefa de regressão supervisionada, na qual as características disponíveis nas observações do Censo são utilizadas para estimar o valor da variável-alvo.

A base utilizada contém dados agregados. Portanto, o modelo não realiza previsões individualizadas sobre estudantes, mas estima quantidades de estudantes desvinculados nas observações disponíveis.

3. Organização do projeto

Parte 1 — Preparação dos dados

Notebook: `Projeto_2_Parte_1(1).ipynb`

Esta etapa contempla:

- Seleção das variáveis relevantes para o problema;
- Análise exploratória dos dados;
- Identificação e tratamento de inconsistências nas variáveis categóricas;
- Investigação e tratamento de valores ausentes;
- Identificação de possíveis valores extremos;
- Análise da assimetria das variáveis numéricas;
- Aplicação de transformações logarítmicas às variáveis de contagem selecionadas;
- Análise de correlação e investigação da multicolinearidade;
- Identificação das variáveis numéricas e categóricas;
- Exportação da base preparada para utilização na etapa de modelagem.

O resultado desta etapa é o arquivo `dados_preparados.csv`, que contém a variável-alvo, os preditores selecionados e as variáveis categóricas ainda não codificadas.

Parte 2 — Modelagem e avaliação

Notebook: `Projeto_2_Parte_2(3).ipynb`

Nesta etapa são realizadas as seguintes atividades:

- Carregamento e verificação da base preparada;
- Separação da variável-alvo `QT_SIT_DESVINCULADO` e das variáveis preditoras;
- Divisão dos dados em conjuntos de treino e teste;
- Construção de um pipeline de pré-processamento;
- Codificação das variáveis categóricas por meio de One-Hot Encoding;
- Imputação de valores ausentes, quando necessário;
- Padronização das variáveis numéricas;
- Treinamento do modelo ElasticNet sem filtragem da variável-alvo;
- Análise dos erros absolutos;
- Filtragem de observações com valores elevados da variável-alvo;
- Otimização dos hiperparâmetros do ElasticNet por validação cruzada;
- Avaliação do modelo nos conjuntos de treino filtrado, teste filtrado e teste completo;
- Salvamento do modelo final.

4. Preparação e pré-processamento

As variáveis foram selecionadas considerando sua relevância para a descrição das características acadêmicas, institucionais e geográficas das observações.

Na etapa de preparação, foram investigados valores ausentes, inconsistências e distribuições assimétricas. Algumas variáveis de contagem apresentaram forte assimetria à direita, motivando a aplicação de transformações logarítmicas.

As variáveis categóricas foram mantidas em sua representação original durante a preparação da base. Na modelagem, elas são codificadas por One-Hot Encoding, enquanto as variáveis numéricas são padronizadas por meio do `StandardScaler`.

Essas operações são incorporadas ao pipeline de modelagem, de modo que o pré-processamento seja ajustado durante o treinamento, evitando que informações do conjunto de teste participem do ajuste das transformações.

5. Modelo de Machine Learning

O algoritmo utilizado é o ElasticNet, um modelo de regressão linear regularizada que combina as penalizações L1 e L2.

Essa abordagem permite controlar a complexidade do modelo e pode ser útil quando existem associações entre as variáveis preditoras.

Os hiperparâmetros `alpha` e `l1_ratio` são investigados por meio de `GridSearchCV`, utilizando validação cruzada com três divisões e o erro absoluto médio (MAE) como critério de seleção.

A avaliação dos modelos utiliza as seguintes métricas:

- MAE (Mean Absolute Error): mede o erro absoluto médio das previsões, expresso na escala da variável-alvo.

- RMSE (Root Mean Squared Error): penaliza mais fortemente erros de grande magnitude.
- R^2 (coeficiente de determinação): avalia quanto da variabilidade da variável-alvo é explicada pelas previsões do modelo.

6. Experimento com filtragem da variável-alvo

Além do treinamento com todos os valores da variável-alvo, foi conduzido um experimento em que as observações com valores superiores ao limite definido pelo quantil 0,88 são excluídas do conjunto de treino.

O limite é calculado exclusivamente a partir da variável-alvo do conjunto de treino. O mesmo limite é utilizado para identificar o subconjunto correspondente no teste.

Essa estratégia permite investigar se o modelo apresenta melhor desempenho na faixa predominante da distribuição de `QT_SIT_DESVINCULADO`.

A avaliação considera três conjuntos:

- Treino filtrado: observações utilizadas no ajuste do modelo;
- Teste filtrado: observações do teste cujos valores reais estão abaixo ou iguais ao limite estabelecido;
- Teste completo: todas as observações do conjunto de teste, incluindo os valores extremos.

Os resultados indicaram desempenho mais consistente nos conjuntos filtrados. Entretanto, a avaliação no teste completo evidenciou dificuldades na previsão das observações de maior magnitude.

A filtragem não significa que os valores extremos sejam necessariamente erros nos dados. Ela representa uma restrição do escopo do modelo, que deve ser considerada na interpretação dos resultados.

7. Modelo salvo

O notebook da etapa de modelagem salva o modelo final otimizado no arquivo:

```
modelo_quantil_elasticnet_otimizado.pkl
```

O arquivo é gerado utilizando a biblioteca `joblib`.

O modelo final corresponde à versão treinada com os dados filtrados e com os hiperparâmetros selecionados pela validação cruzada. O pipeline inclui o pré-processamento das variáveis numéricas e categóricas.

Para utilizar o modelo posteriormente, é necessário carregá-lo com `joblib` e fornecer novos dados com as mesmas variáveis preditoras utilizadas no treinamento, respeitando seus nomes e tipos.

8. Tecnologias utilizadas

- Python;
- Jupyter Notebook;
- Pandas;
- NumPy;
- Matplotlib e Seaborn;
- Scikit-learn;
- Joblib;
- Biblioteca `watermark` para registro de informações do ambiente.

9. Como executar o projeto

- Disponibilize os notebooks e o arquivo `dados_preparados.csv` no ambiente de execução.
- Confira e ajuste os caminhos de leitura dos arquivos nos notebooks, se necessário.
- Execute primeiro o notebook da Parte 1 para reproduzir a preparação dos dados, caso deseje reconstruir a base.
- Execute o notebook da Parte 2 para treinar, otimizar e avaliar os modelos.
- Após a execução da etapa de modelagem, o arquivo `modelo_quantil_elasticnet_otimizado.pkl` será salvo no diretório de trabalho do notebook.

Dependências

As principais bibliotecas necessárias podem ser instaladas com:

```
pip install pandas numpy matplotlib seaborn scikit-learn joblib watermark
```

10. Limitações e trabalhos futuros

Os resultados indicam que o ElasticNet consegue estimar a variável-alvo com maior consistência para observações abaixo do limite de filtragem adotado. Entretanto, o desempenho no conjunto de teste completo é inferior, principalmente devido à dificuldade em representar observações com números elevados de estudantes desvinculados.

Entre as possibilidades de continuidade estão:

- Comparar o ElasticNet com outros algoritmos de regressão;
- Investigar modelos mais adequados a variáveis de contagem;
- Analisar os erros por faixas de valores da variável-alvo;
- Avaliar estratégias que reduzam o impacto dos valores extremos sem excluí-los;
- Investigar outras variáveis preditoras e possíveis fontes de informação;
- Avaliar o desempenho em diferentes anos e contextos institucionais.

Também é importante explicitar que a base não permite acompanhar necessariamente o mesmo curso ao longo do tempo por meio de um identificador único adequado. Portanto, o objetivo desta versão é estimar o número de estudantes desvinculados a partir das características disponíveis na mesma observação, e não prever diretamente o valor futuro de cada curso.

11. Considerações finais

O projeto apresenta um fluxo de trabalho de Ciência de Dados que abrange preparação dos dados, análise exploratória, pré-processamento, modelagem supervisionada, otimização de hiperparâmetros e avaliação de desempenho.

Os experimentos realizados permitem compreender melhor as limitações de um modelo linear regularizado diante de uma variável-alvo assimétrica e com valores extremos. Os resultados também destacam a importância de alinhar o objetivo de previsão à população para a qual o modelo efetivamente apresenta desempenho satisfatório.

O modelo desenvolvido constitui uma etapa exploratória para investigar o potencial de técnicas de Machine Learning na análise de dados do Censo da Educação Superior e pode servir de base para experimentos posteriores voltados ao apoio à análise e à tomada de decisões no contexto educacional.